

Les outils CapiTainS, l'édition numérique et l'exploitation des textes

Thibault Clérice

École Nationale des Chartes / Lyon 3

thibault.clerice@chartes.psl.eu

@pontineptique (Twitter / Github)

CapiTains

Histoire rapide

- Perseus, Perseids, (Leipzig, CHS & Tufts)
- Depuis 2015

Aujourd'hui

- Perseus, École Nationale des Chartes, Hambourg, Alpheios, Perseids
- Principal : 6 logiciels et briques logicielles, 1 set de guidelines

Capitains

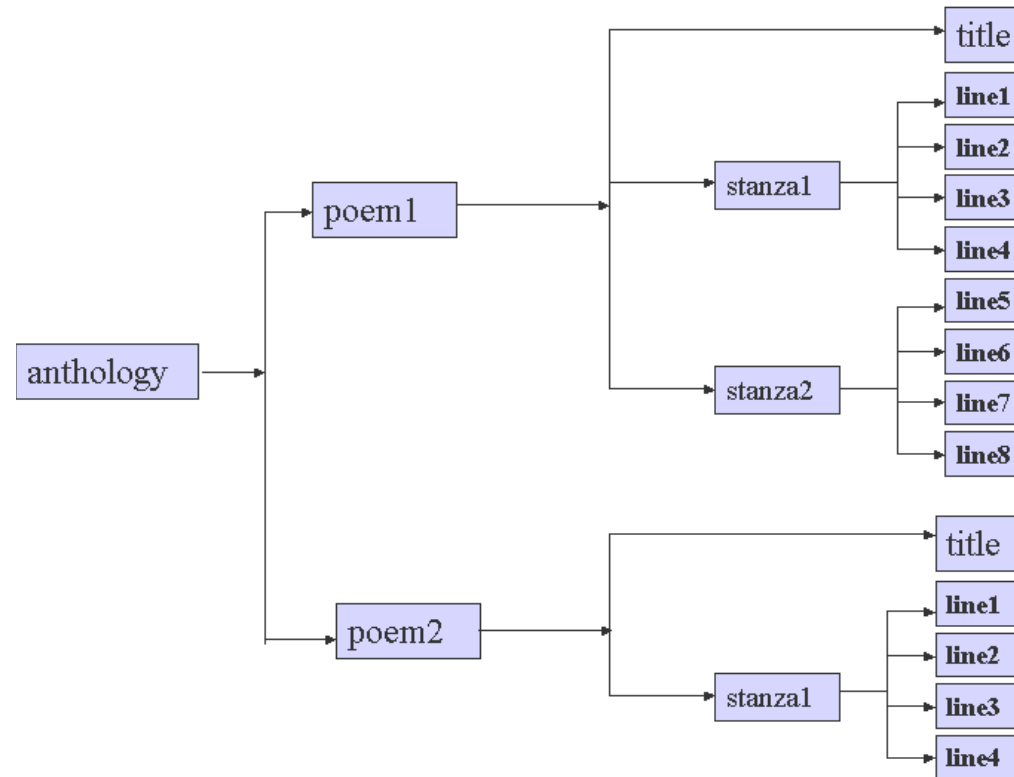
CapiT(ain)S = Citable Text Services for APIs

Objectifs

1. Rendre la mise à disposition de textes plus facile via des API Web (Interfaces web pensées pour les machines)
2. Rendre l'utilisation d'APIs web et de corpus XML plus facile pour la recherche
3. Ne pas sacrifier la liberté éditoriale

La théorie derrière Capitains

Ordered Hierarchy of Content Objects



TEI Consortium, « A Gentle Introduction to XML », *TEI P5 Guidelines* v3.3.0, , <http://www.tei-c.org/release/doc/tei-p5-doc/en/html/SG.html>

Allen H. Renear, Elli Mylonas et David Durand, Refining our notion of what text really is: The problem of overlapping hierarchies », 1993, <https://www.ideals.illinois.edu/handle/2142/9407>.

Guidelines 2.0 - CTS (Depuis 2017)

- Basé pour une compatibilité avec le *Canonical Text Services* 5.0
- Spécifications particulières pour Epidoc ou TEI
- <http://capitains.org/pages/guidelines.html>

Guidelines 3.0 - DTS (Fin 2018)

- Rétro-compatibilité proposée et transformation facilitée.
- En cours de rédaction - <https://github.com/capitains/guidelines>
- Indépendant des systèmes d'identifiants, basé sur DublinCore pour les métadonnées et quelques propriétés d'une ontologie CapiTainS pour les relations "logicielles"

Objectif général

- Les métadonnées de "catalogue" et le texte doivent être séparés pour en faciliter la maintenance
- Le système de citation du texte doit être clair et exprimé dans le texte.

Guidelines 2.0 : les identifiants CTS

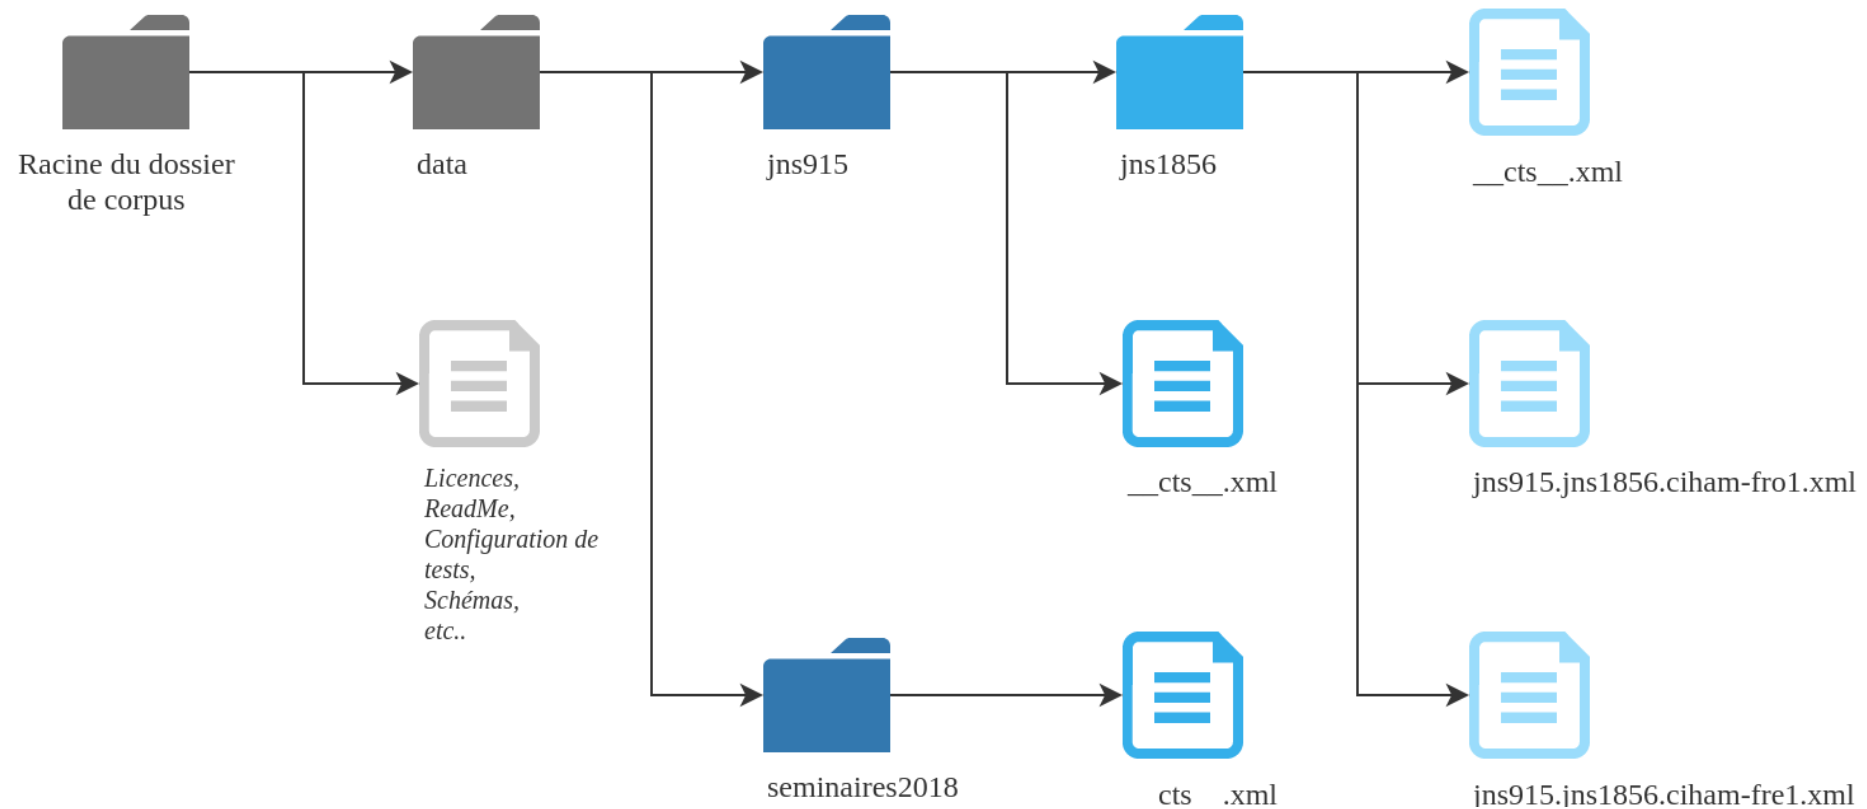
Élément central des guidelines

urn : cts : froLit	:	jns915 . jns1856 .	ciham-fro1	:	1.1-1.2
	namespace	textgroup	work	version	passage
	<i>Littérature en ancien français</i>	<i>Wauchier de Denain</i>	<i>Vie de Saint Martin</i>	<i>Edition d'Ariane Pinche au CIHAM</i>	<i>Entre 1.1 et 1.2</i>

- **namespace**: un espace de nom défini, lié à un projet, une institution ou un cadre plus large (froLit, latinLit, greekLit, etc.)
- **textgroup**: un auteur, un groupe de textes faisant sens ensemble
- **work**: une oeuvre conceptuelle
- **version**: une incarnation de l'oeuvre
- **passage**: une sous-partie

Exemple : urn:cts:ahn:seminaires2018.capitains15.slides

Guidelines 2.0 : structure des dossiers



Guidelines 2.0 : la TEI (en mode Epidoc)

- En TEI non Epidoc, `xml:lang` et `n` seraient sur `<body @n @xml:lang/>` ou `<text @xml:base @n/>`

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <teiHeader>
    <encodingDesc>
      <refsDecl n="CTS">
        <cRefPattern matchPattern="(\w+).(\w+)" n="vers"
          replacementPattern="#xpath(/tei:TEI/tei:text/tei:body/tei:div/tei:div[@n='$1']/tei:l[@n='$2'])"
        />
        <cRefPattern matchPattern="(\w+)" n="poeme"
          replacementPattern="#xpath(/tei:TEI/tei:text/tei:body/tei:div/tei:div[@n='$1'])"/>
      </refsDecl>
    </encodingDesc>
  </teiHeader>
  <text>
    <body>
      <div type="edition OR translation OR commentary"
        xml:lang="fre" n="urn:cts:ahn:seminaires2018.capitains15-poeme.ahn">
        <div type="textpart" subtype="book" n="1"><l n="1">Lorem ipsum</l></div>
      </div>
    </body>
  </text>
</TEI>
```


Guidelines 2.0 : la TEI et sa structure

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <!-- ... -->
  <text>
    <body>
      <div type="edition"
        xml:lang="fre" n="urn:cts:ahn:seminaires2018.capitains15-poeme.ahn">
        <div type="textpart" subtype="book" n="1">
          <l n="1">Lorem ipsum</l>
          <l n="2">ipsum lorem</l>
        </div>
        <div type="textpart" subtype="book" n="2">
          <l n="1">Sed consequat </l>
          <l n="1a">urna non felis dictum</l>
          <l n="2">non tincidunt nibh sagittis</l>
        </div>
      </div>
    </body>
  </text>
</TEI>
```

Guidelines 2.0 : la TEI et son système de citation

- XPath 1 car seul complètement couvert dans tous les langages (dérivés de C, Java, javascript, etc.)
 - XPath 2 publié en janvier 2007, première implémentation en C en 2017 par Saxon
 - Toujours rien en dehors de C Saxon et d'un *wrapper* PHP

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <teiHeader>
    <encodingDesc>
      <refsDecl n="CTS">
        <cRefPattern matchPattern="(\w+).(\w+)" n="vers"
          replacementPattern="#xpath(/tei:TEI/tei:text/tei:body/tei:div/tei:div[@n='$1']/tei:l[@n='$2'])"
        />
        <cRefPattern matchPattern="(\w+)" n="poeme"
          replacementPattern="#xpath(/tei:TEI/tei:text/tei:body/tei:div/tei:div[@n='$1'])"/>
      </refsDecl>
    </encodingDesc>
  </teiHeader>
  <!-- ... -->
</TEI>
```

Phase 1 d'exercice

De nuptiis Philologiae et Mercurii

- `fichiers-travail/De nuptiis Philologiae et Mercurii.xml`
- Identifiant : `urn:cts:latinLit:stoa0192a.stoa001.digilibLT-lat1`

Les fichiers de métadonnées `__cts__.xml`

Textgroup

```
<textgroup xmlns="http://chs.harvard.edu/xmlns/cts" urn="URN jusqu'au *textgroup*">  
  <groupname xml:lang="Langue d'expression du nom">Nom d'auteur ou de groupe</groupname>  
</textgroup>
```

Les fichiers de métadonnées `__cts__.xml`

Work

```
<work
  xmlns="http://chs.harvard.edu/xmlns/cts"
  groupUrn="URN jusqu'au *textgroup*"
  urn="URN jusqu'au *work*"
  xml:lang="Langue principale du texte">
  <title xml:lang="Langue d'expression du titre de l'oeuvre conceptuelle">Titre</title>

  <edition
    urn="URN Complète"
    xml:lang="lat"
    workUrn="URN Work">
    <label xml:lang="Langue d'expression du label">Titre de l'édition</label>
    <description xml:lang="Langue d'expression de la description">
      Description de l'édition
    </description>
  </edition>
</work>
```

Métadonnées avancées

Work

```
<work
  groupUrn="urn:cts:latinLit:phi1103" urn="urn:cts:latinLit:phi1103.phi001" xml:lang="lat"
  xmlns:cpt="http://purl.org/capitains/ns/1.0#" xmlns="http://chs.harvard.edu/xmlns/cts"
  xmlns:dct="http://purl.org/dc/terms/" xmlns:dc="http://purl.org/dc/elements/1.1/">
  <title xml:lang="lat">Priapeia</title>
  <title xml:lang="fre">Priapées</title>

  <edition
    urn="urn:cts:latinLit:phi1103.phi001.lascivaroma-lat1"
    xml:lang="lat" workUrn="urn:cts:latinLit:phi1103.phi001">
    <label xml:lang="eng">Priapeia from Poeta Latini minores</label>
    <description xml:lang="unk">Poeta Latini minores, ed. Aemilius Baehrens,
    Leipzig, Teubner, 1879</description>
    <cpt:structured-metadata>
      <dct:source>https://archive.org/details/poetaelatinimino12baeh2</dct:source>
      <dct:contributor >Thibault Clérice</dct:contributor>
      <dc:language >lat</dc:language>
      <dct:contributor >Aemilius Baehrens</dct:contributor>
      <dc:format >text/xml</dc:format>
      <dc:date>1879</dc:date>
      <dc:author>Anonymous</dc:author>
    </cpt:structured-metadata>
  </edition>
</work>
```

Phase 2 d'exercice

À partir du fichier précédent, réaliser les fichiers de métadonnées puis les mettre dans la structure de dossier évoquée précédemment.

Lien utile pour les squelettes :

- <http://capitains.org/pages/guidelines>
- (Si vous aviez des questions plus tard, en français ou en anglais)
<https://github.com/Capitains/Capitains.github.io/issues>

